PRÀCTICA 2

Mineria de dades

Marc Llort Maulion
marc.llort

Marc Llort Maulion (marc.llort)

Objectiu

Els principals objectius d'aquesta pràctica son:

- Aprendre a dominar el paquet de Python scikit-learn
- Agafar fluïdesa amb la selecció, normalització, preprocés i cerca d'atributs.
- Conèixer les diferents implementacions de l'algorisme d'aprenentatge basat amb exemples IBL.
- Treballar amb el concepte d'optimització d'un learner.

Per dur a terme totes les següents funcionalitats, ens serà necessari prèviament importar les següents llibreries:

```
import scipy
from scipy import stats
import numpy
import sklearn
import sklearn.datasets
from sklearn.model_selection import KFold
from sklearn.decomposition import KernelPCA
from sklearn.decomposition import TruncatedSVD
from sklearn.decomposition import PCA
from sklearn.neighbors import KNeighborsClassifier
import sklearn.metrics
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
import matplotlib.pyplot as pyplot
```

Marc Llort Maulion (marc.llort)

Analitzar el conjunt de dades de dígits (Dígits data set)

En un primer moment, un cop importades les diferents llibreries, ens tocarà carregar els *datasets* de la llibreria “skelearn”:

```
# Carregem datasets

digits = sklearn.datasets.load_digits()

X = digits.data
Y = digits.target
```

Després de carregar els datasets, ens quedarà que a la variable X disposem de una matriu de 1797 files per 64 columnes mentre que a Y tindrem emmagatzemada una matriu de 1797 files per una columna.

Per calcular la mitjana, desviació típica i el nombre d’elements d’entrenament per cada classe: (Cal tenir en compte que tots els càlculs son resultat de fer us del valor de test 3)

```
# 1. Analitzar el conjunt de dades de digits (Digits Data Set)
valorTest = 3

# Numero de mostres per classe
unique, counts = numpy.unique(Y, return_counts=True)
print(dict(zip(unique, counts)))

# Calcul de la mitjana
mitjana = numpy.mean(X[Y == valorTest, :], axis=0)
print("Mitjana ", valorTest, ": ", mitjana)

pyplot.imshow(mitjana.reshape(8, 8), interpolation="none", cmap="Greys")
pyplot.title("Mitjana: " + str(valorTest))
pyplot.show()

# Calcul de la desviacio tipica
std = numpy.std(X, axis=0)
pyplot.imshow(std.reshape(8, 8), interpolation="none", cmap="Greys")
pyplot.title("Desviacio tipica")
pyplot.show()
```

Marc Llort Maulion (marc.llort)

```
>>> runfile('/Users/marcllort/PycharmProjects/MineriaP2/mineriaP2.py', wdir='/Users/marcllort/PycharmProjects/MineriaP2')
{0: 178, 1: 182, 2: 177, 3: 183, 4: 181, 5: 182, 6: 181, 7: 179, 8: 174, 9: 180}
('Mitjana ', array([0.00000000e+00, 6.44808743e-01, 8.38797814e+00, 1.41693989e+01,
       1.42240437e+01, 7.48087432e+00, 7.86885246e-01, 5.46448087e-03,
       1.09289617e-02, 4.20765027e+00, 1.26557377e+01, 8.98907104e+00,
       1.12841530e+01, 1.19945355e+01, 2.10928962e+00, 1.63934426e-02,
       5.46448087e-03, 2.22404372e+00, 3.70491803e+00, 3.10928962e+00,
       1.20273224e+01, 9.32240437e+00, 8.14207650e-01, 0.00000000e+00,
       0.00000000e+00, 2.95081967e-01, 1.45901639e+00, 8.93989071e+00,
       1.42732240e+01, 5.60655738e+00, 8.19672131e-02, 0.00000000e+00,
       0.00000000e+00, 6.01092896e-02, 1.04918033e+00, 5.63934426e+00,
       1.20491803e+01, 1.12786885e+01, 2.19672131e+00, 0.00000000e+00,
       0.00000000e+00, 4.26229508e-01, 1.39890710e+00, 9.67213115e-01,
       4.40983607e+00, 1.21366120e+01, 6.31693989e+00, 0.00000000e+00,
       0.00000000e+00, 8.68852459e-01, 7.11475410e+00, 6.22950820e+00,
       8.26229508e+00, 1.30163934e+01, 5.92896175e+00, 6.55737705e-02,
       0.00000000e+00, 5.02732240e-01, 9.31693989e+00, 1.46502732e+01,
       1.39726776e+01, 8.67213115e+00, 1.40983607e+00, 6.55737705e-02]))
('Desviacio tipica: ', array([0.        , 0.90693964, 4.75350317, 4.24765948, 4.28619491,
       5.66484088, 3.32484969, 1.03709417, 0.09419533, 3.19527098,
       5.41994694, 3.97643575, 4.78134964, 6.05127561, 3.58532293,
       0.82768465, 0.06235094, 3.57530605, 5.68918332, 5.80104695,
       6.17400993, 6.19559718, 3.25896254, 0.43847543, 0.03334258,
       3.14565685, 6.19031469, 5.88129939, 6.15038083, 5.87092136,
       3.68543009, 0.04712725, 0.        , 3.4794038 , 6.32292731,
       6.26664682, 5.93183902, 5.86901393, 3.53629836, 0.        ,
       0.14514503, 2.98098645, 6.53613529, 6.43958504, 6.25776954,
       5.69394162, 4.32974601, 0.30727036, 0.20416633, 1.74566694,
       5.64292531, 5.22549314, 5.30057302, 6.02947606, 4.91803706,
       0.98412698, 0.02358333, 0.9340418 , 5.1015993 , 4.37347662,
       4.93257433, 5.89898069, 4.08940957, 1.85960409]))
```

Els plots resultants de la mitjana i desviació respectivament:

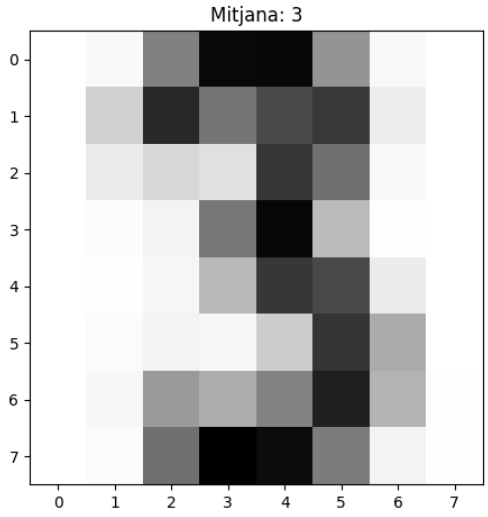

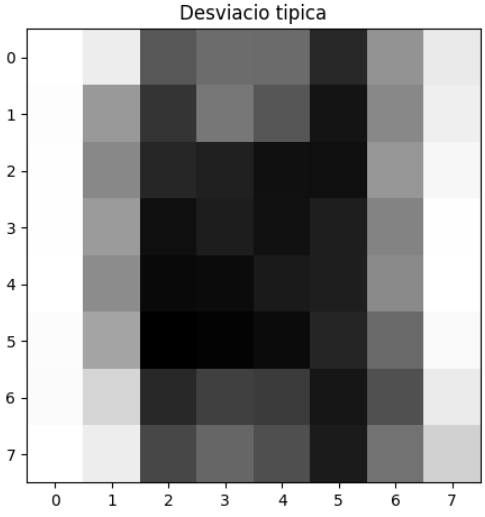

Per dur a terme el Opcional, simplement ens cal, un cop hem importat la llibreria realitzar la següent funció: (el valor de test continua sent el 3)

```
# Opcional: imshow de valorTest
pyplot.imshow(X[valorTest].reshape(8, 8), interpolation="none", cmap="Greys")
pyplot.title("Digit: " + str(Y[valorTest]))
pyplot.show()
```

Marc Llort Maulion (marc.llort)

I el resultat és el següent plot:

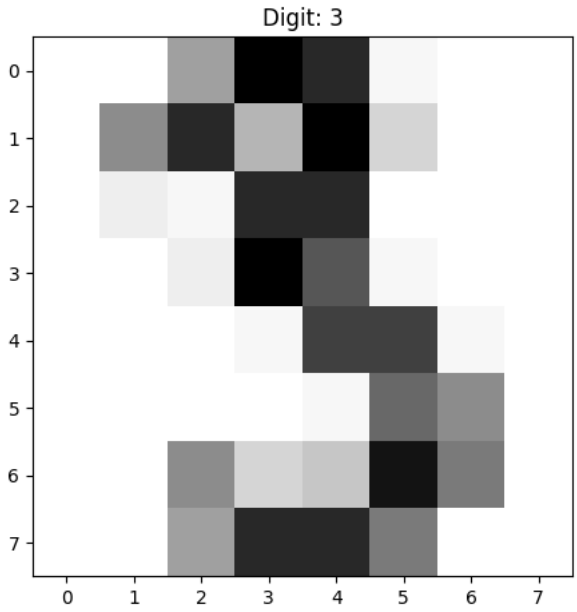

Marc Llort Maulion (marc.llort)

Divisió amb train i test i normalització de les dades

En aquest apartat hem de dividir les variables entre train 70% i test 30%. Un cop dividides hem de normalitzar les dades X (train i test) amb la finalitat d'aconseguir que estiguin centrades a 0 i tinguin una desviació típica de 1.

Per dur a terme aquest apartat farem us de la funció:

```
train_test_split(X, Y, test_size=0.30, train_size=0.70)
```

Aquesta funció divideix les matrius en subconjunts aleatoris de train i test.

El return que proporciona aquesta funció és:

```
split: list, longitud = 2 * len (matrius)
```

On *split* és una llista que conté la divisió de proves de tren de les entrades.
Un cop tenim les dades, cal normalitzar-les:

```
# 2. Divisio amb train i test i normalitzacio de les dades

X_train, X_test, Y_train, Y_test = sklearn.model_selection.train_test_split(X, Y, test_size=0.30, train_size=0.70)
X_train_norm = scipy.stats.zscore(X_train, axis=1, ddof=1)
X_test_norm = scipy.stats.zscore(X_test, axis=1, ddof=1)
```

Marc Llort Maulion (marc.llort)

Projecció en diferents components principals

En aquest apartat farem us de les funcions de sklearn.decomposition.X, on X seran PCA i TruncatedSVD.

Per fer el **anàlisi de components principals (PCA)** farem:

```
# Descomposem les dades amb PCA
pca = PCA(n_components=2).fit_transform(X_train_norm)
pyplot.scatter(pca[:, 0], pca[:, 1], c=Y_train)
pyplot.title("PCA")
pyplot.show()
```

El **PCA** fa una reducció de la dimensionalitat lineal amb descomposició del valor singular de les dades per projectar-la a un espai dimensional més baix.

Fent us de scatterPlot ens quedaria:

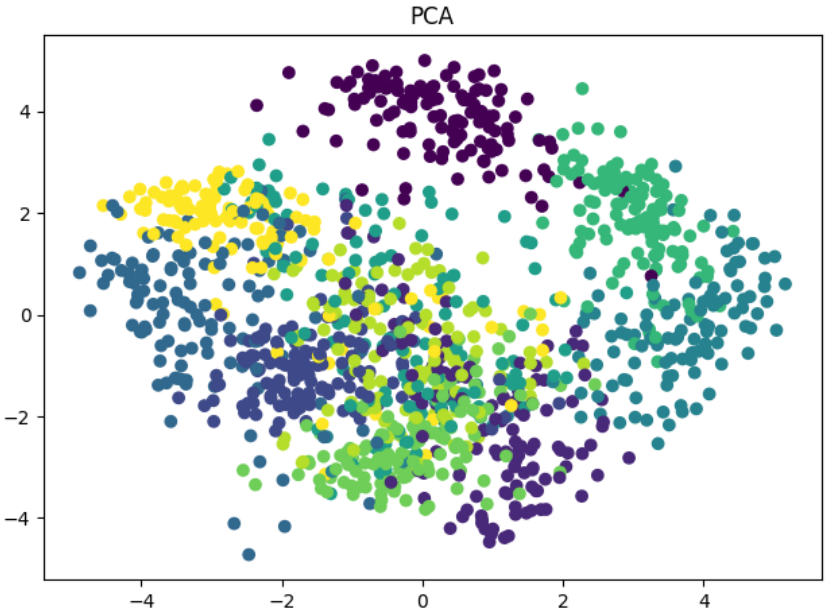

Marc Llort Maulion (marc.llort)

Per fer una **descomposició per valors singulars (SVD)** farem:

```
# Descomposem les dades amb Truncated SVD
svd = TruncatedSVD(n_components=2).fit_transform(X_train_norm)
pyplot.scatter(svd[:, 0], svd[:, 1], c=Y_train)
pyplot.title("Truncated SVD")
pyplot.show()
```

El **SVD** fa una reducció lineal de la dimensionalitat mitjançant la descomposició del valor singular truncat (SVD). Al contrari que PCA, aquest estimador no centra les dades abans de computar la descomposició del valor singular. Això significa que pot treballar amb matrius *scipi.sparse* de manera eficient.

Fent us de scatterPlot ens quedaria:

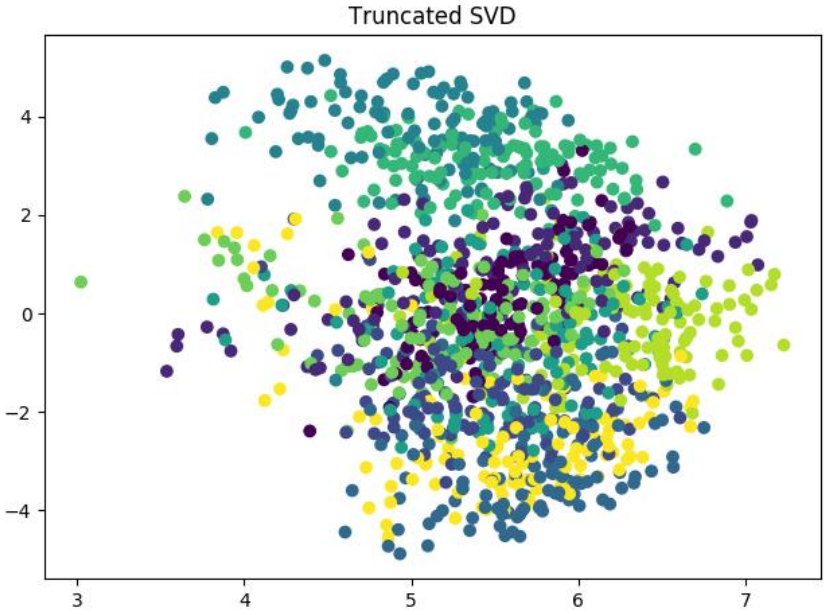

Per últim, una altra opció per fer una descomposició i aconseguir millor separació de dades podem fer us de **KernelPCA**:

```
# Descomposem les dades amb kernel PCA
kernelpca = KernelPCA(n_components=2).fit_transform(X_train_norm)
pyplot.scatter(kernelpca[:, 0], kernelpca[:, 1], c=Y_train)
pyplot.title("Kernel PCA")
pyplot.show()
```

El **KernelPCA** fa una reducció de dimensionalitat no lineal mitjançant l'ús de kernels.

Fent us de scatterPlot ens quedaria:

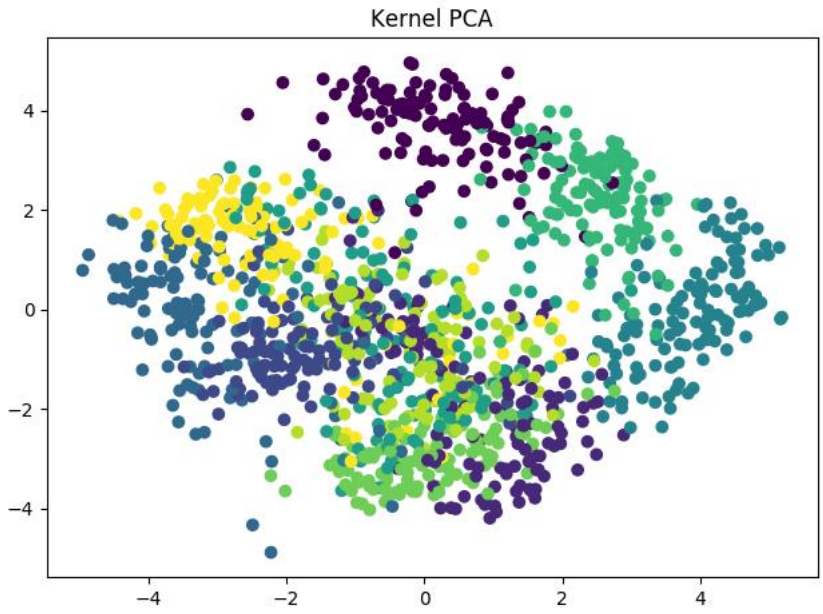

Marc Llort Maulion (marc.llort)

Fes servir validació creuada per estimar el nombre òptim de veïns K

En aquest apartat farem us de la funció:

sklearn.model_selection.KFold

per fer una divisió en 10-fold cross validation per estimar primer el nombre òptim de veïns, el nombre òptim de dimensions.

Primer, definirem la nostra funció de test, on ja tenim combinades les dues funcions per obtenir els valors crossvalidats segons certs paràmetres.

```
for i in range(min_neighbours, max_neighbours):
    values.append(i)

def get_folds(n_splits):
    kfold = KFold(n_splits=n_splits, shuffle=True)
    folds = list(kfold.split(X))
    return folds


def get_predicted(train_X, train_Y, test_X, n_neighbours, weight):
    knearest = KNeighborsClassifier(n_neighbors=n_neighbours, weights=weight)
    model = knearest.fit(train_X, train_Y)
    predicted_y = model.predict(test_X)
    return predicted_y


def compute_test(n_splits, min_neighbours, max_neighbours, weight):
    # Veins i dimensions optimes
    folds = get_folds(n_splits)
    scores = []

    # Proves amb numero de veins variant
    for i in range(min_neighbours, max_neighbours):
        success = 0
        total = 0

        for j in range(len(folds)):
            train, test = folds[j]

            x_train = [X[k] for k in train]
            x_test = [X[k] for k in test]
            y_train = [Y[k] for k in train]
            y_test = [Y[k] for k in test]

            # Prediccio en base al classificador
            predicted_y = get_predicted(x_train, y_train, x_test, i, weight)

            for k in range(len(y_test)):
                total = total + 1
                if y_test[k] == predicted_y[k]:
                    success = success + 1

        scores.append(float(success) / (float(total)) * 100)
    return scores


scores = compute_test(n_splits, min_neighbours, max_neighbours, weight)

# Resultats
fig = pyplot.figure()
ax = fig.add_subplot(111)
ax.plot(values, scores, color='red', linewidth=2)
ax.set_xlim(min_neighbours, max_neighbours)
pyplot.title(weight + " using SVD")
pyplot.xlabel("Neighbours")
pyplot.ylabel("Accuracy")
pyplot.show()
```

Marc Llort Maulion (marc.llort)

A continuació, tenim els gràfics generats utilitzant la ponderació amb PCA i SVD amb els mètodes uniforme i distancia:

PCA:

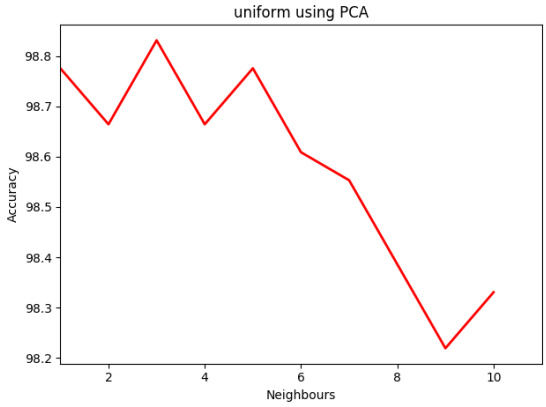

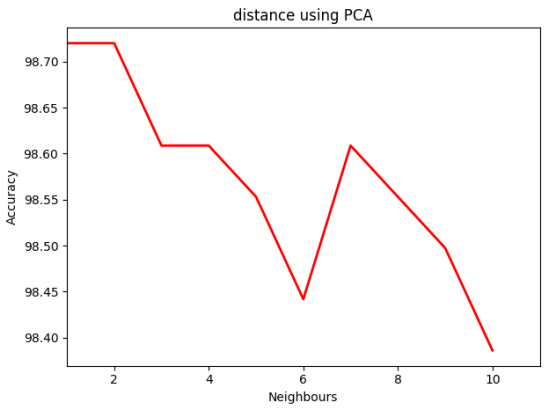

SVD:

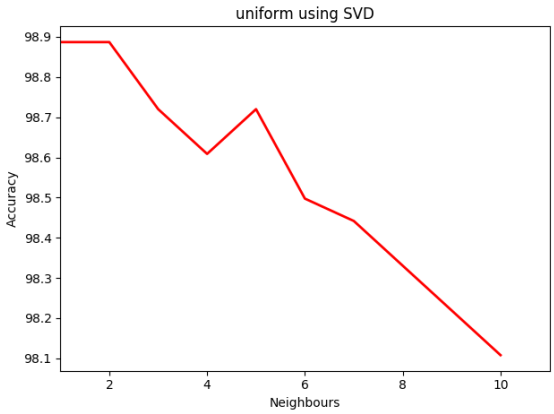

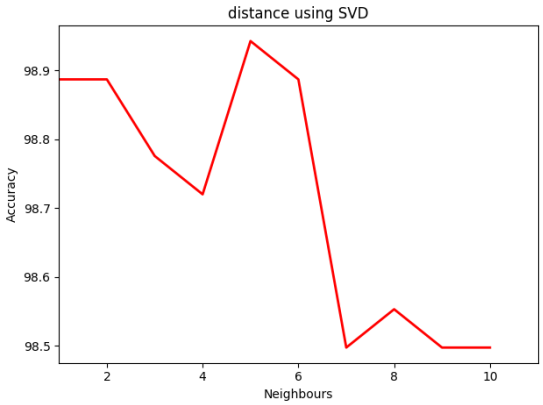

Marc Llort Maulion (marc.llort)

Conclusions

a) Explicació l'efecte de la dimensionalitat en KNN

És important recordar que els píxels fan referencia a imatges, per tant podem saber que totes les dimensions fan referencia als píxels.
En aquest cas, al tenir tantes dimensions disponibles podem millorar la precisió. També cal tenir en compte però, que a partir de cert nombre de dimensions, no millorarem pràcticament la nostra precisió i nomes farem que el temps d'execució sigui més alt per acabar obtenint gairebé els mateixos resultats, és per això que és important trobar la relació correcta.

b) Com comprens i entens els resultats

Hem aconseguit tenir una precisió de un 98% o més al fer servir els diferents algorismes, per tant crec que els resultats són molt bons ja que el nombre de errors es gairebé nul i per tant som molt precisos.